

Decomposição QR para resolver problemas de quadrados mínimos

Dyckson Ternoski
Marina Sayuri Vieira
Monique Baptista Fragozo
Otávio Dittrich Moreira

UFPR - Cálculo Numérico - 3º Semestre


1. Introdução

1.1. Problema de Quadrados Mínimos

Na matemática, é muito importante o estudo de sistemas de equações lineares, pois modelam vários fenômenos em diversos casos. Sabemos, porém, que nem sempre conseguimos obter uma solução exata. Por exemplo, em uma indústria de molas, é necessário especificar a *constante da mola* proveniente da Lei de Hooke, em homenagem ao físico inglês Robert Hooke (1635 - 1703):

$$F = -kx$$

Onde F é a força aplicada à mola e x o deslocamento obtido. Para obtê-la, realizam diversas medidas variando a força e medindo o deslocamento. Porém, toda medição sempre é acometida por um erro, o que torna quase impossível que os valores gerem um sistema consistente, caindo em uma situação como a da figura abaixo.



Como decidir qual é a melhor reta? Melhor em que sentido? Sigamos com a formulação do problema.

Nesse exemplo, as medidas formam o seguinte sistema de equações:

$$\begin{aligned} kx_1 + p &= F_1 \\ kx_2 + p &= F_2 \\ &\vdots \\ kx_m + p &= F_m \end{aligned}$$

onde F_i representa a força aplicada e x_i o deslocamento observado, para $i = 1, 2, \dots, m$, sendo m o número de medições. As incógnitas do problema são k e p .


Como resolver esse tipo de problema?

Em um sistema $Ax = b$ inconsistente, sabemos que b não pertence ao espaço coluna de A . Então para obter uma solução razoável devemos trabalhar com um vetor relativamente próximo de b que pertença a $\mathcal{R}(A)$. Sabemos da Álgebra Linear que o melhor que podemos conseguir é a projeção ortogonal de b sobre $\mathcal{R}(A)$, obtendo o seguinte problema:

$$A\tilde{x} = \text{proj}_{\mathcal{R}(A)} b = Pb \quad (1)$$

para algum projetor P . Assim temos um sistema consistente. O vetor $b - Pb$ será o vetor erro. Como queremos que o erro seja o menor possível, estaremos interessados em encontrar \tilde{x} tal que $b - Pb$ seja o menor possível, ou seja, que minimize a norma $\|b - Pb\|$, ou analogamente, $\|b - Pb\|^2$, donde deriva o nome *quadrados mínimos*.

Da figura da esquerda fica claro que, para que o vetor $A\tilde{x} - b$ for ortogonal ao espaço-coluna de A . O projetor p deve ser, portanto, ortogonal, como na figura da direita.



Assim, se $A\tilde{x} - b$ for ortogonal ao espaço-coluna de A , $b - A\tilde{x}$ temos pelo Teorema Fundamental da Álgebra Linear que:

$$A^t(b - A\tilde{x}) = 0$$

isto é,

$$A^t A\tilde{x} = A^t b \quad (2)$$

Para que o sistema (2) possua uma única solução, é necessário que a matriz quadrada $A^t A$ seja invertível e, se for, precisaremos calcular essa inversa. Para sistemas grandes essa tarefa será computacionalmente custosa, mas como evitá-la? [1]. Nesse trabalho focaremos em uma das formas de resolver isso: *A decomposição QR*.

2. Fundamentação teórica

2.1. Matrizes ortogonais

Generalizaremos aqui o conceito de ortogonalidade entre vetores, definiremos a matriz ortogonal e listaremos suas propriedades, que é o grande foco da decomposição QR. As demonstrações dos teoremas e proposições podem ser encontradas em [2].

Definição 1 Os vetores q_1, q_2, \dots, q_n são ditos ortogonais quando o produto interno $\langle q_i, q_j \rangle$ é zero sempre que $i \neq j$. Geometricamente, vetores ortogonais são perpendiculares dois a dois.

Teorema 1 Um conjunto de vetores ortogonais não nulos são linearmente independentes.

Definição 2 Os vetores v_1, \dots, v_n são ditos normais quando tem norma unitária. E são ditos ortonormais se são ortogonais e normais, ou seja:

$$\langle q_i, q_j \rangle = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

Uma matriz com os vetores coluna ortonormais é dita ortogonal e denotaremos-a por Q .

Definição 3 A decomposição QR de uma matriz A é o par de matrizes Q e R , ortogonal e triangular superior, respectivamente, satisfazendo $A = QR$.

Proposição 1 A matriz Q satisfaz $Q^t Q = I$.

Observação: Quando Q é uma matriz quadrada, Q é invertível se, e somente se $Q^{-1} = Q^t$.

Exemplo 1: (Rotações) Toda matriz de rotação é ortogonal. A matriz Q_θ que rotaciona um vetor no plano por um ângulo θ é:

$$Q_\theta = \begin{pmatrix} \cos\theta & -\text{sen}\theta \\ \text{sen}\theta & \cos\theta \end{pmatrix}$$

Logo, os vetores coluna são:

$$q_1 = \begin{pmatrix} \cos\theta \\ \text{sen}\theta \end{pmatrix} \quad q_2 = \begin{pmatrix} -\text{sen}\theta \\ \cos\theta \end{pmatrix}$$

Assim, temos:

$$\langle q_1, q_1 \rangle = \cos(\theta)^2 + \text{sen}(\theta)^2 = 1$$

$$\langle q_2, q_2 \rangle = (-\text{sen}(\theta))^2 + \cos(\theta)^2 = 1$$

$$\langle q_1, q_2 \rangle = \cos(\theta)(-\text{sen}(\theta)) + \text{sen}(\theta)\cos(\theta) = 0$$

$$\langle q_2, q_1 \rangle = (-\text{sen}(\theta))\cos(\theta) + \cos(\theta)\text{sen}(\theta) = 0$$

Portanto Q_θ é ortogonal.

Proposição 2 Se Q é uma matriz ortogonal, então Q preserva a norma.

Demonstração: De fato, se x é um vetor, pela proposição 1:

$$\|Qx\|^2 = \langle Qx, Qx \rangle = (Qx)^t(Qx) = x^t Q^t Q x = x^t x = \langle x, x \rangle = \|x\|^2$$

Como $\|Qx\|, \|x\| \geq 0$, então $\|Qx\| = \|x\|$.

2.2. Fatoração QR por Gram-Schmidt

Podemos realizar a fatoração QR pelo algoritmo de Gram-Schmidt. O método consiste em utilizar projeções para ortogonalizar os vetores-coluna.

Seja $A \in \mathbb{R}^{n \times n}$ uma matriz com colunas linearmente independentes, isto é, os vetores coluna a_1, a_2, \dots, a_n são linearmente independentes. Então, podemos utilizar o processo de ortogonalização de Gram-Schmidt no conjunto $B = \{a_1, \dots, a_n\}$, obtendo elementos não nulos e ortogonais \hat{q}_k , da forma:

$$\hat{q}_k = a_k - \sum_{j=1}^{k-1} r_{jk} q_j, \quad (3)$$

onde $r_{ik} = \langle v_k, q_i \rangle$, para $i = 1, \dots, k-1$.

Além disso, obtemos vetores ortonormais q_k , normalizando os vetores \hat{q}_k , da seguinte forma:

$$q_k = \frac{\hat{q}_k}{r_{kk}}, \quad k = 1, \dots, n \quad (4)$$

onde $r_{kk} = \|\hat{q}_k\|_2 > 0$, pois os a_k são L.I.
Juntando as equações (3) e (4), obtemos:

$$a_k = \sum_{j=1}^{k-1} r_{jk} q_j + r_{kk} q_k, \quad k = 1, \dots, n$$

Ou então:

$$\begin{aligned} a_1 &= q_1 r_{11} \\ a_2 &= q_1 r_{12} + q_2 r_{22} \\ &\vdots \\ a_n &= q_1 r_{1n} + q_2 r_{2n} + \dots + q_n r_{nn} \end{aligned}$$

Estas equações podem ser escritas como um produto matricial:

$$\begin{bmatrix} a_1 & a_2 & \dots & a_n \end{bmatrix} = \begin{bmatrix} q_1 & q_2 & \dots & q_n \end{bmatrix} \begin{bmatrix} r_{11} & r_{12} & \dots & r_{1n} \\ 0 & r_{22} & \dots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & r_{nn} \end{bmatrix} \Leftrightarrow A = QR$$

Note que a matriz Q é ortogonal, pois suas colunas são vetores ortonormais e R é uma matriz triangular superior com diagonal positiva. Assim, obtemos a fatoração ortogonal $A = QR$ da matriz A , como no algoritmo abaixo.

Algoritmo 1: QR POR GRAM-SCHMIDT

Entrada: $A \in \mathbb{R}^{m \times n}$ $A = (a_1, a_2, \dots, a_n)$; $ntol = 1e-12$

Saída: Q, R Decomposição QR de A

```

1 início
2    $q_1 \leftarrow \frac{a_1}{\|a_1\|}$ 
3   para  $i$  de 2 à  $m$  faça
4      $w_i \leftarrow a_i - \sum_{j=1}^{i-1} \langle q_j, a_i \rangle q_j$ 
5     se  $\|w_i\| \leq ntol$  então
6       | Erro: Norma de  $w_i$  muito próxima de 0
7     fim
8      $q_i \leftarrow \frac{w_i}{\|w_i\|}$ 
9   fim
10   $Q \leftarrow (q_1, q_2, \dots, q_n)$ 
11   $R = Q^t A$ 
12  retorna  $Q, R$ 
13 fim
```

No exemplo abaixo, ilustraremos o algoritmo para uma matriz $A \in \mathbb{R}^{3 \times 3}$

$$A = \begin{pmatrix} 1 & 2 & 3 \\ -1 & 0 & -3 \\ 0 & -2 & 3 \end{pmatrix}$$

Assim, temos:

$$a_1 = \begin{pmatrix} 1 & -1 & 0 \end{pmatrix} \quad a_2 = \begin{pmatrix} 2 & 0 & -2 \end{pmatrix} \quad a_3 = \begin{pmatrix} 3 & -3 & 3 \end{pmatrix}$$

Logo:

$$\begin{aligned}
 q_1 &= \frac{a_1}{\|a_1\|} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 & 0 \end{pmatrix} \\
 \Rightarrow w_2 &= a_2 - \langle q_1, a_2 \rangle q_1 = \begin{pmatrix} 1 & 1 & 2 \end{pmatrix} \\
 \Rightarrow q_2 &= \frac{w_2}{\|w_2\|} = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 & 1 & 2 \end{pmatrix} \\
 \Rightarrow w_3 &= a_3 - \langle q_1, a_3 \rangle q_1 - \langle q_2, a_3 \rangle q_2 = \begin{pmatrix} 1 & 1 & 1 \end{pmatrix} \\
 \Rightarrow q_3 &= \frac{1}{\sqrt{3}} \begin{pmatrix} 1 & 1 & 1 \end{pmatrix}
 \end{aligned}$$

Portanto:

$$Q = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ -1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ 0 & -2/\sqrt{6} & 1/\sqrt{3} \end{pmatrix} \quad e \quad R = Q^t A = \begin{pmatrix} \sqrt{2} & \sqrt{2} & \sqrt{18} \\ 0 & \sqrt{6} & -\sqrt{6} \\ 0 & 0 & \sqrt{3} \end{pmatrix}$$

2.3. Fatoração QR por Rotações de Givens

A fatoração QR também pode ser feita a partir de rotações de um ângulo θ no plano. Esse método consiste em usar os elementos da diagonal principal para zerar os elementos abaixo deles usando matrizes de rotação. Logo abaixo temos o algoritmo da fatoração QR por rotação de Givens:

Algoritmo 2: QR POR ROTAÇÕES DE GIVENS

Entrada: $A \in \mathbb{R}^{m \times n}$ $A = (a_1, a_2, \dots, a_n)^t$

Saída: Q, R Decomposição QR de A

```

1 início
2    $Q = (q_1, q_2, \dots, q_n)^t = \text{Identidade } n \times n$ 
3   para  $j$  de 1 à  $n$  faça
4     para  $i$  de  $j+1$  à  $m$  faça
5       se  $a_{ij} \neq 0$  então
6          $c_{ij} \leftarrow a_{jj} / \sqrt{a_{jj}^2 + a_{ij}^2}$  Supondo  $a_{ij}, a_{jj} \neq 0$ 
7          $s_{ij} \leftarrow a_{ij} / \sqrt{a_{jj}^2 + a_{ij}^2}$ 
8          $a_j, a_i \leftarrow a_j c_{ij} + a_i s_{ij}, a_j(-s_{ij}) + a_i c_{ij}$ 
9          $q_j, q_i \leftarrow q_j c_{ij} + q_i s_{ij}, q_j(-s_{ij}) + q_i c_{ij}$ 
10      fim
11    fim
12  fim
13   $Q \leftarrow Q^t$ 
14   $R \leftarrow A$ 
15  retorna  $Q, R$ 
16 fim

```

Vejamos um exemplo para a matriz $A \in \mathbb{R}^{3 \times 3}$

$$A = \begin{pmatrix} 1 & 2 & 3 \\ -1 & 0 & 3 \\ 0 & -2 & 3 \end{pmatrix}$$

Temos:

$$a_1 = (1 \ 2 \ 3) \ a_2 = (-1 \ 0 \ -3) \ a_3 = (0 \ -2 \ 3)$$

$$c_{12} = \frac{a_{11}}{\sqrt{a_{11}^2 + a_{12}^2}} = \frac{1}{\sqrt{2}}$$

$$s_{12} = \frac{a_{12}}{\sqrt{a_{11}^2 + a_{12}^2}} = \frac{-1}{\sqrt{2}}$$

$$\Rightarrow a_1 \leftarrow a_1 c_{12} + a_2 s_{12} = \frac{1}{\sqrt{2}} (2 \ 2 \ 6)$$

$$\Rightarrow a_2 \leftarrow a_1(-s_{12}) + a_2 c_{12} = \frac{1}{\sqrt{2}} (0 \ 2 \ 0)$$

$$\Rightarrow q_1 \leftarrow q_1 c_{12} + q_2 s_{12} = \frac{1}{\sqrt{2}} (1 \ -1 \ 0)$$

$$\Rightarrow q_2 \leftarrow q_1(-s_{12}) + q_2 c_{12} = \frac{1}{\sqrt{2}} (1 \ 1 \ 0)$$

Como $a_{13} = 0$, seguimos para o próximo passo.

$$c_{23} = \frac{a_{22}}{\sqrt{a_{22}^2 + a_{23}^2}} = \frac{\sqrt{2}}{\sqrt{6}}$$

$$s_{23} = \frac{a_{23}}{\sqrt{a_{22}^2 + a_{23}^2}} = \frac{-2}{\sqrt{6}}$$

$$\Rightarrow a_2 \leftarrow a_2 c_{23} + a_3 s_{23} = \frac{1}{\sqrt{6}} (0 \ 6 \ -6)$$

$$\Rightarrow a_3 \leftarrow a_2(-s_{23}) + a_3 c_{23} = \frac{1}{\sqrt{3}} (0 \ 0 \ 3)$$

$$\Rightarrow q_2 \leftarrow q_2 c_{12} + q_3 s_{12} = \frac{1}{\sqrt{6}} (1 \ 1 \ -2)$$

$$\Rightarrow q_3 \leftarrow q_2(-s_{12}) + q_3 c_{12} = \frac{1}{\sqrt{3}} (1 \ 1 \ 1)$$

Logo, como esperado:

$$Q = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ -1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ 0 & -2/\sqrt{6} & 1/\sqrt{3} \end{pmatrix} \quad e \quad R = \begin{pmatrix} \sqrt{2} & \sqrt{2} & \sqrt{18} \\ 0 & \sqrt{6} & -\sqrt{6} \\ 0 & 0 & \sqrt{3} \end{pmatrix}$$

2.4. Problema de Quadrados Mínimos Lineares

Definição 4 Seja $A \in \mathbb{R}^{m \times n}$ ($m > n$) e $b \in \mathbb{R}^m$. Considere $r = b - Ax$. O problema de quadrados mínimos de (A, b) é achar $x \in \mathbb{R}^n$ tal que $\|r\|^2$ seja mínima, ou seja, $\min_{x \in \mathbb{R}^n} \|b - Ax\|_2^2$.

Teorema 2 (Solução Única do Problema de Quadrados Mínimos) Seja $A \in \mathbb{R}^{m \times n}$ e $b \in \mathbb{R}^m$, $m > n$ tal que $\text{posto}(A) = n$ (posto completo). Então o problema de quadrados mínimos tem solução única e pode ser encontrada resolvendo o sistema não singular $\hat{R}x = \hat{c}$, onde $\begin{pmatrix} \hat{c} \\ d \end{pmatrix} = c = Q^T b$, $\hat{R} \in \mathbb{R}^{n \times n}$ é triangular superior e $Q \in \mathbb{R}^{m \times n}$ é ortogonal.

De fato, se Q, R é a decomposição QR de A , pelas proposições 1 e 2:

$$\|Ax - b\|_2^2 = \|QRx - b\|_2^2 = \|Q^T(QRx - b)\|_2^2 = \|Rx - Q^T b\|_2^2$$

Considere $\hat{R} \in \mathbb{R}^{n \times n}$, $\hat{c} \in \mathbb{R}^{n \times n}$ e $d \in \mathbb{R}^{m-n \times n}$ tal que $R = \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix}$ $Q^T b = \begin{pmatrix} \hat{c} \\ d \end{pmatrix}$. Temos:

$$\left\| \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix} x - \begin{pmatrix} \hat{c} \\ d \end{pmatrix} \right\|_2^2 = \|\hat{R}x - \hat{c}\|_2^2 + \|d\|_2^2$$

Portanto, x é solução do problema de quadrados mínimos se, e somente se $\|\hat{R}x - \hat{c}\|_2^2 = 0$ com \hat{R} triangular superior.

A resolução de quadrados mínimos é dada pelo algoritmo abaixo:

Algoritmo 3: RESOLUÇÃO DE QUADRADOS MÍNIMOS

Entrada: $A \in \mathbb{R}^{n \times m}$, $b \in \mathbb{R}^{m \times 1}$

Saída: $\tilde{x} \in \mathbb{R}^{m \times 1}$ solução de $\min_{x \in \mathbb{R}^m} \|Ax - b\|_2^2$

1 **início**

2 $Q, R \leftarrow$ Decomposição QR de A

3 $R_1 \leftarrow R[1 : m, :]$

4 $b \leftarrow Q^T b$

5 $b_1 \leftarrow b[1 : m]$

6 $\tilde{x} \leftarrow R_1^{-1} b_1$

7 **retorna** \tilde{x}

8 **fim**

Na prática, não é necessário calcular R_1^{-1} , pois é triangular superior. Basta encontrar x por retrossubstituição.

Voltemos ao exemplo da mola. Suponha que as medições realizadas foram:

$$4.0k + p = 2.614$$

$$6.0k + p = 5.7309$$


$$8.0k + p = 7.2909$$

$$10.0k + p = 6.4058$$

$$12.0k + p = 9.6112$$

$$14.0k + p = 12.9009$$

Representando graficamente temos:



Podemos escrever esse sistema em notação matricial como:

$$Ax = b$$

Onde,

$$A = \begin{pmatrix} 4.0 & 1.0 \\ 6.0 & 1.0 \\ 8.0 & 1.0 \\ 10.0 & 1.0 \\ 12.0 & 1.0 \\ 14.0 & 1.0 \end{pmatrix}; \quad x = \begin{pmatrix} k \\ p \end{pmatrix} \text{ e } b = \begin{pmatrix} 2.614 \\ 5.7309 \\ 7.2909 \\ 6.4058 \\ 9.6112 \\ 12.9009 \end{pmatrix}$$

Assim, basta resolver o problema de quadrados mínimos de (A,b).

Aplicando o algoritmo de decomposição QR por rotações em A, obtemos:

$$Q = \begin{pmatrix} 0.169638 & 0.703585 & -0.408248 & 0.365148 & 0.316228 & 0.276026 \\ 0.254457 & 0.480094 & 0.816497 & -0.182574 & 0.000000 & 0.069007 \\ 0.339276 & 0.256602 & -0.408248 & -0.730297 & -0.316228 & -0.138013 \\ 0.424094 & 0.033110 & 0.000000 & 0.547723 & -0.632456 & -0.345033 \\ 0.508913 & -0.190382 & 0.000000 & 0.000000 & 0.632456 & -0.552052 \\ 0.593732 & -0.413874 & 0.000000 & 0.000000 & 0.000000 & 0.690066 \end{pmatrix}$$

$$R = \begin{pmatrix} -23.5797 & -2.2901 \\ 0.0000 & -0.8691 \\ 0.0000 & 0.0000 \\ 0.0000 & 0.0000 \\ 0.0000 & 0.0000 \\ 0.0000 & 0.0000 \end{pmatrix}$$

$$\Rightarrow R_1 \leftarrow \begin{pmatrix} -23.5797 & -2.2901 \\ 0.0000 & -0.8691 \end{pmatrix}$$


$$\Rightarrow b_1 \leftarrow Q^t b = \begin{pmatrix} 19.6429 \\ -0.4956 \\ 0.6356 \\ -1.9077 \\ 0.5483 \\ 1.4971 \end{pmatrix}$$

$$\Rightarrow \tilde{x} \leftarrow R^{-1} Q^t b = \begin{pmatrix} 0.8884 \\ -0.5703 \end{pmatrix}$$

Ou seja,

$$k = 0.8884 \text{ e } p = -0.5703$$

Graficamente:



Portanto, a melhor aproximação que temos é:

$$F = 0.0884x - 0.5703$$

3. Metodologia e Análise

Como vimos anteriormente, a fatoração QR pode ser feita de duas maneiras: usando o processo de Gram-Schmidt ou usando rotações de Givens. Veremos as vantagens e desvantagens de cada um dos métodos implementados em nosso código nessa seção (o código está disponível na **Seção 4**, nas considerações finais). Além disso, veremos em detalhes o problema de quadrados mínimos implementado pela equipe funcionando a partir da decomposição QR com cada um dos métodos implementados.

3.1. Fatoração QR

3.1.1. QR por Gram-Schmidt

O processo de Gram-Schmidt ortogonaliza os vetores coluna da matriz com projeções, obtendo Q, e a R surge como consequência. É instável numericamente, pois a ortogonalização feita no processo é propensa a erros numéricos. Uma vantagem significativa, no entanto, é a facilidade de implementação.

3.1.2. QR por rotação de Givens

Na fatoração QR por rotação, em cada nova iteração zeramos um elemento da matriz encontrada na iteração anterior; se estivermos na primeira iteração, zeramos um elemento da matriz A. Os elementos são zerados com o intuito de deixar a matriz no formato triangular superior, ou seja, encontramos nossa matriz R. Uma vantagem desse método é que cada novo elemento zero a_{ij} afeta apenas a linha com o elemento a ser zerado (i) e uma linha acima (j), o que torna o algoritmo mais eficiente.

3.2. Quadrados Mínimos

Nesta subseção, observaremos as principais diferenças entre a fatoração QR por Gram-Schmidt e por rotação de Givens na hora de calcularmos uma solução para o problema de quadrados mínimos.

3.2.1. Tempo e Memória

Utilizamos a biblioteca BenchmarkTools para calcular o tempo que o código leva para encontrar a solução de quadrados mínimos e ver a quantidade de memória que foi utilizada enquanto o código rodava. Essa biblioteca nos permite também ver o quanto de memória foi utilizada enquanto o código roda, além de nos mostrar o número de alocações. Observe os resultados obtidos em alguns exemplos numéricos:

Exemplo 1: Considerando as matrizes A e b abaixo:

$$A = \begin{pmatrix} 0.0 & 1.0 \\ 1.0 & 1.0 \\ 2.0 & 1.0 \\ 3.0 & 1.0 \\ 4.0 & 1.0 \end{pmatrix} \quad b = \begin{pmatrix} -5 \\ 0 \\ 5 \\ 12 \\ 24 \end{pmatrix}$$

Temos:

$$Q = \begin{pmatrix} 0.000000 & 0.774597 & -0.408248 & 0.365148 & -0.316228 \\ 0.182574 & 0.516398 & 0.816497 & -0.182574 & 0.000000 \\ 0.365148 & 0.258199 & -0.408248 & -0.730297 & -0.316228 \\ 0.547723 & 0.000000 & 0.000000 & 0.547723 & -0.632456 \\ 0.730297 & -0.258199 & 0.000000 & 0.000000 & 0.632456 \end{pmatrix} \quad e \quad R = \begin{pmatrix} 5.47723 & 1.82574 \\ 0.00000 & 1.29099 \\ 0.00000 & 0.00000 \\ 0.00000 & 0.00000 \\ 0.00000 & 0.00000 \end{pmatrix}$$

$$\text{Solução do problema de quadrados mínimos: } x = \begin{pmatrix} 7.0 \\ -6.8 \end{pmatrix}$$

Para chegar nas soluções acima, as alocações, memória e tempo foram os seguintes:

	Tempo	Alocações	Memória
Gram-Schmidt	0.0000009651 segundos	24 allocations	2.66 KiB
Rotação	0.0000052995 segundos	151 allocations	16.78 KiB

Neste exemplo, o processo de Gram-Schmidt é muito mais eficiente.

O Exemplo 1 é um exemplo qualquer, a matriz A não tem nada "especial", agora vejamos os exemplos a seguir.

Exemplo 2: (Matrizes esparsas) Utilizamos a biblioteca SparseArrays para criar uma matriz $A \in \mathbb{R}^{10 \times 10}$ esparsa arbitrária e criamos um vetor $b \in \mathbb{R}^{10}$, também arbitrário. Obtivemos os seguintes dados:

	Tempo	Alocações	Memória
Gram-Schmidt	0.0000150070 segundos	351 allocations	57.81 KiB
Rotação	0.0000021864 segundos	30 allocations	8.02 KiB

Neste exemplo, ao contrário do exemplo 1, o método das rotações de Givens é mais eficiente.

Exemplo 3: (Matrizes densas) Criando uma matriz densa arbitrária $A \in \mathbb{R}^{10 \times 10}$ e $b \in \mathbb{R}^{10}$ um vetor arbitrário, obtivemos:

	Tempo	Alocações	Memória
Gram-Schmidt	0.0000152320 segundos	351 allocations	57.81 KiB
Rotação	0.0000409430 segundos	910 allocations	145.52 KiB

Novamente, nesse exemplo, o método mais vantajoso é o processo de Gram-Schmidt.

3.2.2. Explicação dos resultados e conclusão

Após ver os 3 exemplos e comparar os resultados de tempo e memória utilizada para cada um deles, há uma pergunta relevante a ser respondida: Por que obtivemos esses resultados?

Nos exemplos 2 e 3 podemos ver uma diferença gigantesca entre os valores obtidos, principalmente se tratando de memória utilizada e alocações, sendo que no exemplo 2, a rotação é muito melhor que Gram-Schmidt e no exemplo 3 temos totalmente o contrário.

Isso acontece porque para matrizes esparsas o método da rotação é de fato muito mais eficiente, pois quando o aplicamos, procuramos zerar elementos da matriz para encontrar a matriz R no formato triangular superior. Se a matriz já tem vários zeros (esparsa), então não precisamos zerá-los, portanto, o algoritmo da rotação pulará diversos passos.

Já para matrizes densas, como no exemplo 3, não há zeros na matriz 10×10 (a densidade tem coeficiente 1), e portanto, para o método de rotação é necessário zerar diversas entradas dela, em vez de "pular" algumas, como acontece com matrizes esparsas. Por conta disso, o método de Gram-Schmidt se torna mais vantajoso, já que utiliza menos memória e realiza menos alocações comparado ao método da rotação de Givens.

Como no exemplo 1 pegamos uma matriz $A \in \mathbb{R}^{5 \times 2}$ não esparsa e obtivemos um melhor desempenho do processo de Gram-Schmidt, então era de se esperar que para uma matriz densa 10×10 (exemplo 3) acontecesse o mesmo.

Concluimos que não há maneira mais eficiente de se calcular a fatoração QR, já que para o caso de matrizes esparsas, o preferível é utilizar das rotações de Givens e, para matrizes densas, o melhor é o processo de Gram-Schmidt.

3.2.3. Retas

Utilizamos a biblioteca Plots para gerar um gráfico com a reta que aproxima pontos dados. No Exemplo 1 da seção anterior, tínhamos as seguintes matrizes:

$$A = \begin{pmatrix} 0.0 & 1.0 \\ 1.0 & 1.0 \\ 2.0 & 1.0 \\ 3.0 & 1.0 \\ 4.0 & 1.0 \end{pmatrix} \quad b = \begin{pmatrix} -5 \\ 0 \\ 5 \\ 12 \\ 24 \end{pmatrix}$$

Sendo z um vetor de incógnitas $z = \begin{pmatrix} c \\ d \end{pmatrix}$

Ao resolver $Az = b$, geramos o seguinte sistema linear:

$$0c + d = -5$$

$$1c + d = 0$$

$$2c + d = 5$$

$$3c + d = 12$$

$$4c + d = 24$$

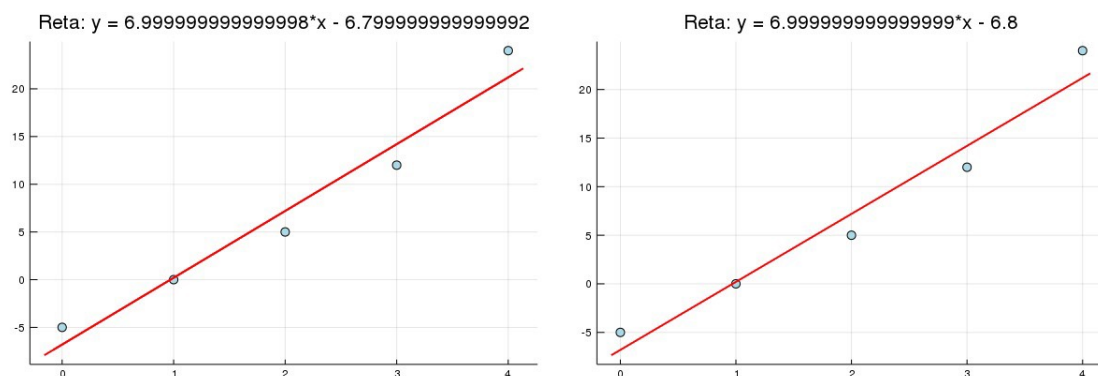
Cada uma dessas equações representa uma função afim. Na primeira equação, por exemplo, temos a função $y = cx + d$, sendo $x = 0$ e $y = -5$.

Como os coeficientes c e d são os mesmos para todas as equações, e nosso objetivo é achar o vetor $z = \begin{pmatrix} c \\ d \end{pmatrix}$, então resolver o sistema $Az = b$ é equivalente a achar a função afim de coeficiente angular c e linear d tal que a reta (gráfico dessa função) seja aquela que passa mais perto dos pontos: $(0, -5)$, $(1, 0)$, $(2, 5)$, $(3, 12)$, $(4, 24)$.

Portanto, dados: x um vetor que contém as abscissas dos pontos e y o vetor que contém as ordenadas, encontramos a equação da reta desejada simplesmente por resolver o sistema $Az = b$.

$$x = \begin{pmatrix} 0.0 \\ 1.0 \\ 2.0 \\ 3.0 \\ 4.0 \end{pmatrix} \quad y = \begin{pmatrix} -5 \\ 0 \\ 5 \\ 12 \\ 24 \end{pmatrix} \quad \text{Solução obtida: } z = \begin{pmatrix} 7.0 \\ -6.8 \end{pmatrix}$$

E portanto, obtivemos a seguinte reta aproximada: $y = 7.0x - 6.8$. Abaixo estão os gráficos obtidos ao gerar a reta resolvendo o sistema $Az = b$ por Gram-Schmidt e por rotação de Givens, respectivamente.



Podemos perceber que ao construir a reta, não há diferenças muito significativas entre Gram-Schmidt e rotação de Givens, afinal, apesar de um método ser mais eficiente que outro, o resultado obtido é o mesmo.

4. Considerações finais

Por fim, segue link do diretório do Github contendo o código para avaliação: <https://github.com/dycksont/Fatoracao-QR-e-Quadrados-Minimos>

Referências

- [1] ARAUJO, T.P., *Álgebra Linear: Teoria e Aplicações* Barbacena, Textos Universitários. Sociedade Brasileira de Matemática, 2014.
- [2] STRANGE, G. *Introduction to Linear ALgebra* Wellesley, Cambridge Press, 2009.
- [3] LIMA, E. L. , *Álgebra Linear* IMPA.
- [4] LANG, S., *Álgebra Linear*, Springer, 1973
- [5] WATKINS,D. S.*Introduction to Matrix Computation*, Wiley-Interscience, 2002.
- [6] STEWART,G.W.,*Introduction to Matrix Computation*, Academic Press, 1973.
- [7] AXLER, Sheldon, *Linear Algebra Done Right*, Springer, 2004.