

# Fatoração QR e seu uso para resolver o problema de quadrados mínimos

---

Dyckson Ternoski

Marina Sayuri Vieira

Monique Baptista Fragozo

Otávio Dittrich Moreira

Orientador: Prof. Abel Soares Siqueira

J3M - 06 de novembro de 2019

UFPR - Universidade Federal do Paraná

# Introdução e Motivação

---

# Problema de Quadrados Mínimos

Um dos problemas mais importantes em aplicações matemáticas é a resolução de sistemas lineares da forma:

$$Ax = b \tag{1}$$

onde  $A \in \mathbb{R}^{m \times n}$  e  $b \in \mathbb{R}^m$ .

# Problema de Quadrados Mínimos

Quando  $m > n$ , temos um sistema com mais equações do que incógnitas e (1) pode não ter solução. Nesse caso, a melhor estratégia é resolver o **Problema de Quadrados Mínimos**:

# Problema de Quadrados Mínimos

Quando  $m > n$ , temos um sistema com mais equações do que incógnitas e (1) pode não ter solução. Nesse caso, a melhor estratégia é resolver o **Problema de Quadrados Mínimos**:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

# Problema de Quadrados Mínimos

Isso envolve resolver o sistema

$$A^tAx = A^tb$$

o qual possui solução única

$$x = (A^tA)^{-1}A^tb$$

sempre que A tem vetores coluna L.I.

# Problema de Quadrados Mínimos

Isso envolve resolver o sistema

$$A^tAx = A^tb$$

o qual possui solução única

$$x = (A^tA)^{-1}A^tb$$

sempre que A tem vetores coluna L.I.

Porém, a inversão de matrizes é computacionalmente custosa.  
Haveria uma forma de evitá-la?

# Decomposição QR

---



**Definição 1:** *Um conjunto de vetores  $q_1, q_2, \dots, q_n$  é dito ortonormal quando são ortogonais dois a dois e tem norma unitária, ou seja:*

**Definição 1:** Um conjunto de vetores  $q_1, q_2, \dots, q_n$  é dito ortonormal quando são ortogonais dois a dois e tem norma unitária, ou seja:

$$\langle q_i, q_j \rangle = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

**Definição 1:** Um conjunto de vetores  $q_1, q_2, \dots, q_n$  é dito ortonormal quando são ortogonais dois a dois e tem norma unitária, ou seja:

$$\langle q_i, q_j \rangle = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

Uma matriz  $Q$  é dita ortogonal quando seus vetores coluna são ortonormais, ou seja,  $Q^t Q = I$ .

# Matrizes Ortogonais

**Exemplo 1:** (Rotações) Toda matriz de rotação é ortogonal.

A matriz  $Q_\theta$  que rotaciona um vetor no plano por um ângulo  $\theta$  é:

$$Q_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$$

# Matrizes Ortogonais

**Exemplo 1:** (Rotações) Toda matriz de rotação é ortogonal.

A matriz  $Q_\theta$  que rotaciona um vetor no plano por um ângulo  $\theta$  é:

$$Q_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$$

Logo, os vetores coluna são:

$$q_1 = \begin{pmatrix} \cos\theta \\ \sin\theta \end{pmatrix} \quad q_2 = \begin{pmatrix} -\sin\theta \\ \cos\theta \end{pmatrix}$$

Portanto:

$$\langle q_1, q_1 \rangle = \cos(\theta)^2 + \sin(\theta)^2 = 1$$

$$\langle q_2, q_2 \rangle = (-\sin(\theta))^2 + \cos(\theta)^2 = 1$$

$$\langle q_1, q_2 \rangle = \cos(\theta)(-\sin(\theta)) + \sin(\theta)\cos(\theta) = 0$$

$$\langle q_2, q_1 \rangle = (-\sin(\theta))\cos(\theta) + \cos(\theta)\sin(\theta) = 0$$

**Proposição 1:** *Se  $Q$  é uma matriz ortogonal então  $Q$  preserva a norma.*

**Proposição 1:** *Se  $Q$  é uma matriz ortogonal então  $Q$  preserva a norma.*

De fato,

$$\|Qv\|_2^2 = (Qv)^t Qv = v^t Q^t Qv = v^t v = \|v\|_2^2$$

**Proposição 2:** *O produto de matrizes ortogonais é uma matriz ortogonal.*



**Proposição 2:** *O produto de matrizes ortogonais é uma matriz ortogonal.*

Demonstração: Se  $Q_1$  e  $Q_2$  são matrizes ortogonais, então:

$$\begin{aligned}(Q_1 Q_2)^t (Q_1 Q_2) &= Q_2^t Q_1^t Q_1 Q_2 \\ &= Q_2^t Q_2 \\ &= I\end{aligned}$$

**Proposição 2:** *O produto de matrizes ortogonais é uma matriz ortogonal.*

Demonstração: Se  $Q_1$  e  $Q_2$  são matrizes ortogonais, então:

$$\begin{aligned}(Q_1 Q_2)^t (Q_1 Q_2) &= Q_2^t Q_1^t Q_1 Q_2 \\ &= Q_2^t Q_2 \\ &= I\end{aligned}$$

Ou seja,  $Q_1 Q_2$  é ortogonal. É facilmente estendido por indução para  $n$  matrizes.

**Definição 2:** Dizemos que o par de matrizes  $(Q, R)$  é a decomposição QR de  $A$  quando:

$$A = QR$$

Sendo  $Q$  ortogonal e  $R$  triangular superior.

**Definição 2:** Dizemos que o par de matrizes  $(Q, R)$  é a decomposição QR de  $A$  quando:

$$A = QR$$

Sendo  $Q$  ortogonal e  $R$  triangular superior.

Como podemos calcular a decomposição QR?

# Decomposição QR por Gram-Schmidt

**Teorema 1:** *Seja  $A \in \mathbb{R}^{m \times n}$  com colunas L.I.. Podemos usar o processo de Gram-Schmidt nas colunas  $a_1, a_2, \dots, a_n$  da matriz  $A$  e normalizá-las, obtendo elementos  $q_1, q_2, \dots, q_n$  para encontrar a decomposição QR, sendo:*

$$Q = (q_1 \ q_2 \ \dots \ q_n) \text{ e } R = Q^t A$$

# Decomposição QR por Gram-Schmidt

**Teorema 1:** *Seja  $A \in R^{m \times n}$  com colunas L.I.. Podemos usar o processo de Gram-Schmidt nas colunas  $a_1, a_2, \dots, a_n$  da matriz  $A$  e normalizá-las, obtendo elementos  $q_1, q_2, \dots, q_n$  para encontrar a decomposição QR, sendo:*

$$Q = (q_1 \ q_2 \ \dots \ q_n) \text{ e } R = Q^t A$$

Ou seja,

$$w_i = a_i - \sum_{j=1}^{i-1} \langle q_j, a_i \rangle q_j \Rightarrow q_i = \frac{w_i}{\|w_i\|} \quad \forall i = 1, \dots, n$$

e

$$R_{ij} = \begin{cases} \langle q_i, a_j \rangle & \text{se } i \leq j \\ 0 & \text{caso contrário} \end{cases}$$

**Exemplo 2:** Calcular a decomposição QR pelo processo de Gram-Schmidt da matriz :

$$A = \begin{pmatrix} 1 & 2 & 3 \\ -1 & 0 & -3 \\ 0 & -2 & 3 \end{pmatrix}$$

## Decomposição QR por Gram-Schmidt

**Exemplo 2:** Calcular a decomposição QR pelo processo de Gram-Schmidt da matriz :

$$A = \begin{pmatrix} 1 & 2 & 3 \\ -1 & 0 & -3 \\ 0 & -2 & 3 \end{pmatrix}$$

Aplicando Gram-Schmidt nas colunas de A e normalizando-as, obtemos:

$$q_1 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \\ 0 \end{pmatrix} \quad q_2 = \begin{pmatrix} 1/\sqrt{6} \\ 1/\sqrt{6} \\ -2/\sqrt{6} \end{pmatrix} \quad q_3 = \begin{pmatrix} 1/\sqrt{3} \\ 1/\sqrt{3} \\ 1/\sqrt{3} \end{pmatrix}$$



# Decomposição QR por Gram-Schmidt

Assim:

$$Q = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ -1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ 0 & -2/\sqrt{6} & 1/\sqrt{3} \end{pmatrix}$$

e

$$R = Q^t A = \begin{pmatrix} \sqrt{2} & \sqrt{2} & \sqrt{18} \\ 0 & \sqrt{6} & -\sqrt{6} \\ 0 & 0 & \sqrt{3} \end{pmatrix}$$

# Decomposição QR por Rotações de Givens

Podemos também encontrar a decomposição QR por um método chamado **Rotações de Givens**:

# Decomposição QR por Rotações de Givens

Podemos também encontrar a decomposição QR por um método chamado **Rotações de Givens**:

**Teorema 2:** *Se  $A$  é uma matriz com vetores coluna L.I., então existem matrizes de rotação  $Q_1, Q_2, \dots, Q_n$  tais que:*

$$Q_1 Q_2 \dots Q_n A = R$$

*Sendo  $R$  triangular superior.*

Portanto, se  $Q = Q_n^t Q_{n-1}^t \dots Q_1^t$ , então:

$$A = QR$$

é uma decomposição QR de  $A$ .

# Decomposição QR por Rotações de Givens

Para o caso em que  $A \in \mathbb{R}^{5 \times 5}$

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{14} & a_{15} \\ a_{21} & a_{22} & a_{23} & a_{24} & a_{25} \\ a_{31} & a_{32} & a_{33} & a_{34} & a_{35} \\ a_{41} & a_{42} & a_{43} & a_{44} & a_{45} \\ a_{51} & a_{52} & a_{53} & a_{54} & a_{55} \end{pmatrix}$$

Teremos:

# Decomposição QR por Rotações de Givens

$$\cos(\theta_{21}) = \frac{a_{11}}{\sqrt{a_{11}^2 + a_{21}^2}} \quad \sin(\theta_{21}) = \frac{a_{21}}{\sqrt{a_{11}^2 + a_{21}^2}}$$

$$\begin{pmatrix} \cos(\theta_{21}) & \sin(\theta_{21}) & 0 & 0 & 0 \\ -\sin(\theta_{21}) & \cos(\theta_{21}) & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} A$$

# Decomposição QR por Rotações de Givens

$$\cos(\theta_{21}) = \frac{a_{11}}{\sqrt{a_{11}^2 + a_{21}^2}} \quad \sin(\theta_{21}) = \frac{a_{21}}{\sqrt{a_{11}^2 + a_{21}^2}}$$

$$\begin{pmatrix} \cos(\theta_{21}) & \sin(\theta_{21}) & 0 & 0 & 0 \\ -\sin(\theta_{21}) & \cos(\theta_{21}) & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} A$$

$\Downarrow$

$$\begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & a_{14}^{(1)} & a_{15}^{(1)} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & a_{24}^{(1)} & a_{25}^{(1)} \\ a_{31} & a_{32} & a_{33} & a_{34} & a_{35} \\ a_{41} & a_{42} & a_{43} & a_{44} & a_{45} \\ a_{51} & a_{52} & a_{53} & a_{54} & a_{55} \end{pmatrix}$$

# Decomposição QR por Rotações de Givens

$$\cos(\theta_{31}) = \frac{a_{11}^{(1)}}{\sqrt{a_{11}^{(1)2} + a_{31}^2}} \quad \sin(\theta_{31}) = \frac{a_{31}}{\sqrt{a_{11}^{(1)2} + a_{31}^2}}$$

$$\begin{pmatrix} \cos(\theta_{31}) & 0 & \sin(\theta_{31}) & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ -\sin(\theta_{31}) & 0 & \cos(\theta_{31}) & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} Q_{21}A$$

# Decomposição QR por Rotações de Givens

$$\cos(\theta_{31}) = \frac{a_{11}^{(1)}}{\sqrt{a_{11}^{(1)2} + a_{31}^2}} \quad \sin(\theta_{31}) = \frac{a_{31}}{\sqrt{a_{11}^{(1)2} + a_{31}^2}}$$

$$\begin{pmatrix} \cos(\theta_{31}) & 0 & \sin(\theta_{31}) & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ -\sin(\theta_{31}) & 0 & \cos(\theta_{31}) & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} Q_{21}A$$

$\Downarrow$

$$\begin{pmatrix} a_{11}^{(2)} & a_{12}^{(2)} & a_{13}^{(2)} & a_{14}^{(2)} & a_{15}^{(2)} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & a_{24}^{(1)} & a_{25}^{(1)} \\ 0 & a_{32}^{(1)} & a_{33}^{(1)} & a_{34}^{(1)} & a_{35}^{(1)} \\ a_{41} & a_{42} & a_{43} & a_{44} & a_{45} \\ a_{51} & a_{52} & a_{53} & a_{54} & a_{55} \end{pmatrix}$$



# Decomposição QR por Rotações de Givens

E assim por diante, até chegarmos no último passo:

$$\cos(\theta_{54}) = \frac{a_{44}^{(3)}}{\sqrt{a_{44}^{(3)2} + a_{54}^2}} \quad \sin(\theta_{54}) = \frac{a_{54}}{\sqrt{a_{44}^{(3)2} + a_{54}^2}}$$

$$\begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & \cos(\theta_{54}) & \sin(\theta_{54}) \\ 0 & 0 & 0 & -\sin(\theta_{54}) & \cos(\theta_{54}) \end{pmatrix} Q_{53} Q_{43} Q_{52} Q_{42} Q_{32} Q_{51} Q_{41} Q_{31} Q_{21} A$$

# Decomposição QR por Rotações de Givens

E assim por diante, até chegarmos no último passo:

$$\cos(\theta_{54}) = \frac{a_{44}^{(3)}}{\sqrt{a_{44}^{(3)2} + a_{54}^2}} \quad \sin(\theta_{54}) = \frac{a_{54}}{\sqrt{a_{44}^{(3)2} + a_{54}^2}}$$

$$\begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & \cos(\theta_{54}) & \sin(\theta_{54}) \\ 0 & 0 & 0 & -\sin(\theta_{54}) & \cos(\theta_{54}) \end{pmatrix} Q_{53} Q_{43} Q_{52} Q_{42} Q_{32} Q_{51} Q_{41} Q_{31} Q_{21} A$$

$\Downarrow$

$$\begin{pmatrix} r_{11} & r_{12} & r_{13} & r_{14} & r_{15} \\ 0 & r_{22} & r_{23} & r_{24} & r_{25} \\ 0 & 0 & r_{33} & r_{34} & r_{35} \\ 0 & 0 & 0 & r_{44} & r_{45} \\ 0 & 0 & 0 & 0 & r_{55} \end{pmatrix}$$

# Decomposição QR por Rotações de Givens

Como cada matriz  $Q_{ij}$  é ortogonal, então:

$$A = (Q_{54}Q_{53}Q_{43}Q_{52}Q_{42}Q_{32}Q_{51}Q_{41}Q_{31}Q_{21})^t \begin{pmatrix} r_{11} & r_{12} & r_{13} & r_{14} & r_{15} \\ 0 & r_{22} & r_{23} & r_{24} & r_{25} \\ 0 & 0 & r_{33} & r_{34} & r_{35} \\ 0 & 0 & 0 & r_{44} & r_{45} \\ 0 & 0 & 0 & 0 & r_{55} \end{pmatrix}$$

# Decomposição QR por Rotações de Givens

Logo, se

$$Q = (Q_{54}Q_{53}Q_{43}Q_{52}Q_{42}Q_{32}Q_{51}Q_{41}Q_{31}Q_{21})^t$$

E

$$R = \begin{pmatrix} r_{11} & r_{12} & r_{13} & r_{14} & r_{15} \\ 0 & r_{22} & r_{23} & r_{24} & r_{25} \\ 0 & 0 & r_{33} & r_{34} & r_{35} \\ 0 & 0 & 0 & r_{44} & r_{45} \\ 0 & 0 & 0 & 0 & r_{55} \end{pmatrix}$$

Então, pela proposição 2, Q é ortogonal.

Portanto (Q,R) é uma decomposição QR de A.

# Quadrados mínimos via decomposição QR

Como a decomposição QR ajuda no Problema de Quadrados Mínimos?

# Quadrados mínimos via decomposição QR

Como a decomposição QR ajuda no Problema de Quadrados Mínimos?

Se  $A = QR$ , pela Proposição 1, podemos resolver o Problema de Quadrados Mínimos de  $(A, b)$  como

$$\begin{aligned}\|Ax - b\|_2^2 &= \|QRx - b\|_2^2 \\ &= \|Q^t(QRx - b)\|_2^2 \\ &= \|Rx - Q^tb\|_2^2 \\ &= \|\hat{R}x - c\|_2^2 + \|d\|_2^2\end{aligned}$$

Onde

$$R = \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix} \quad Q^tb = \begin{pmatrix} c \\ d \end{pmatrix}$$

Assim, basta resolver o sistema triangular  $\hat{R}x = c$

**Exemplo 3:** Ajuste de curva por uma reta nos seguintes pontos:

|   |    |   |   |    |    |
|---|----|---|---|----|----|
| x | 0  | 1 | 2 | 3  | 4  |
| y | -5 | 0 | 5 | 12 | 24 |

**Exemplo 3:** Ajuste de curva por uma reta nos seguintes pontos:

|   |    |   |   |    |    |
|---|----|---|---|----|----|
| x | 0  | 1 | 2 | 3  | 4  |
| y | -5 | 0 | 5 | 12 | 24 |

Assim, sendo  $y = ax + c$  a reta procurada, temos:

$$\begin{cases} 0a + c = -5 \\ 1a + c = 0 \\ 2a + c = 5 \\ 3a + c = 12 \\ 4a + c = 24 \end{cases}$$



## Quadrados mínimos via decomposição QR

Reescrevendo o sistema linear de equações como  $Ax = b$ , com  $A \in \mathbb{R}^{5 \times 2}$  e  $b \in \mathbb{R}^{5 \times 1}$  obtemos :

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{pmatrix} \quad b = \begin{pmatrix} -5 \\ 0 \\ 5 \\ 12 \\ 24 \end{pmatrix}$$

## Quadrados mínimos via decomposição QR

Calculando a decomposição QR de A, obtemos:

$$Q = \begin{pmatrix} 0 & 0.774597 \\ 0.182574 & 0.516398 \\ 0.365148 & 0.258199 \\ 0.547723 & 0 \\ 0.730297 & -0.258199 \end{pmatrix}$$

$$\hat{R} = \begin{pmatrix} 5.47723 & 1.82574 \\ 0 & 1.29099 \end{pmatrix} \quad c = \begin{pmatrix} 25.92553 \\ -8.77876 \end{pmatrix}$$

## Quadrados mínimos via decomposição QR

Calculando a decomposição QR de A, obtemos:

$$Q = \begin{pmatrix} 0 & 0.774597 \\ 0.182574 & 0.516398 \\ 0.365148 & 0.258199 \\ 0.547723 & 0 \\ 0.730297 & -0.258199 \end{pmatrix}$$

$$\hat{R} = \begin{pmatrix} 5.47723 & 1.82574 \\ 0 & 1.29099 \end{pmatrix} \quad c = \begin{pmatrix} 25.92553 \\ -8.77876 \end{pmatrix}$$

Resolvendo  $\hat{R}x = c$ :

$$x = \begin{pmatrix} 7 \\ -6.8 \end{pmatrix}$$

# Quadrados mínimos via decomposição QR

Logo, a reta que melhor ajusta a curva é:

$$y \approx 7x - 6.8$$

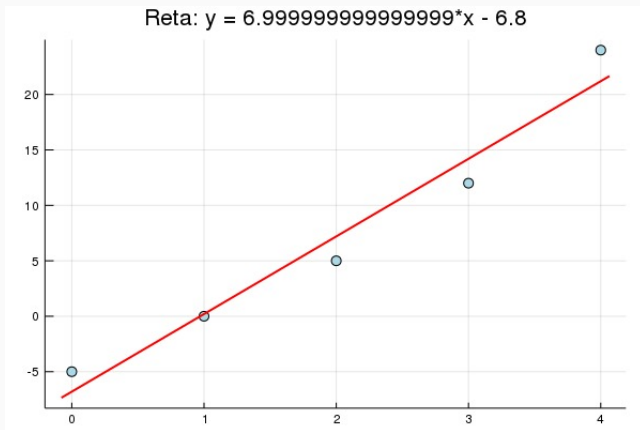


Figura 1: Gráfico do Exemplo 3.

Qual dos métodos de fatora  o   computacionalmente melhor?  
Vamos analisar os dados do exemplo anterior:

Qual dos métodos de fatoração é computacionalmente melhor?  
Vamos analisar os dados do exemplo anterior:

|              | Tempo                 | Alocações | Memória   |
|--------------|-----------------------|-----------|-----------|
| Gram-Schmidt | 0.0000009651 segundos | 24        | 2.66 KiB  |
| Rotação      | 0.0000052995 segundos | 151       | 16.78 KiB |

Vemos que, para este exemplo, Gram-Schmidt é mais eficiente.  
Vejam agora outros exemplos:

**Exemplo 4:** Matriz esparsa  $50 \times 50$  aleatória.

|              | Tempo                 | Alocações | Memória     |
|--------------|-----------------------|-----------|-------------|
| Gram-Schmidt | 0.0018660880 segundos | 7760      | 4.482 MiB   |
| Rotação      | 0.0000968360 segundos | 255       | 227.344 KiB |

Aqui, rotação de Givens é o método mais vantajoso.

# Comparações de eficiência

**Exemplo 4:** Matriz esparsa  $50 \times 50$  aleatória.

|              | Tempo                 | Alocações | Memória     |
|--------------|-----------------------|-----------|-------------|
| Gram-Schmidt | 0.0018660880 segundos | 7760      | 4.482 MiB   |
| Rotação      | 0.0000968360 segundos | 255       | 227.344 KiB |

Aqui, rotação de Givens é o método mais vantajoso.

**Exemplo 5:** Matriz densa  $100 \times 100$  aleatória.

|              | Tempo                 | Alocações | Memória    |
|--------------|-----------------------|-----------|------------|
| Gram-Schmidt | 0.0161613560 segundos | 30580     | 29.833 MiB |
| Rotação      | 0.0524124630 segundos | 99020     | 84.979 MiB |

Desta vez, Gram-Schmidt teve melhor desempenho.



Voltamos a nossa pergunta inicial:

“É possível evitar o alto custo computacional do uso da inversa de matrizes?”

Voltamos a nossa pergunta inicial:

“É possível evitar o alto custo computacional do uso da inversa de matrizes?”

**Exemplo 6:** Matriz  $5 \times 5$  aleatória.

|                          | Tempo                 | Alocações | Memória   |
|--------------------------|-----------------------|-----------|-----------|
| Gram-Schmidt             | 0.000009102 segundos  | 101       | 12.67 KiB |
| Rotação                  | 0.000007645 segundos  | 90        | 12.06 KiB |
| $x = (A^t A)^{-1} A^t B$ | 0.0000207507 segundos | 230       | 29.81 KiB |

# Conclusões

---

Como a decomposição QR por rotações de Givens depende da necessidade de zerar elementos, então com **matrizes esparsas** o gasto é mínimo.

$$A = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & -3 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 2 & 0 & 0 & 0 & 5 \\ 0 & 0 & 0 & 7 & 0 \end{pmatrix}$$

Exemplo de matriz esparsa (precisamos zerar apenas dois elementos)

Já para **matrizes densas**, Gram-Schmidt é melhor, pois agora o método da rotação não “pulará” entradas de A, e realizará portanto, muitas alocações.

$$A = \begin{pmatrix} 1 & 3 & 5 & 2 & 12 \\ 4 & 1 & 1 & 3 & 11 \\ 5 & 2 & \pi & 4 & 5 \\ 7 & 1 & 2 & 7 & 9 \\ 2 & 5 & 7 & 8 & 1 \end{pmatrix}$$

Por fim, podemos afirmar que a escolha do método de decomposição QR depende das características da matriz escolhida.

Entretanto é sempre uma vantagem preferir QR à inversão de matrizes, devido à economia de tempo, alocações e memória.

## Objetivos futuros

---

→ Criar uma alternativa computacional ao método das Reflexões de Householder. Para isso:

- Desenvolver uma função seletora dos métodos estudados
- Diminuir o gasto de memória



## Referências

---

- [1] ARAUJO, T. P. *Álgebra Linear: Teoria e Aplicações: 1. Ed.* Rio de Janeiro: SBM, 2014.
- [2] STRANGE, G. *Introduction to Linear Algebra: 4. Ed.* Wellesley: Wellesley-Cambridge Press, 2009.
- [3] WATKINS, D. S. *Fundamentals of Matrix Computations: 2. Ed.* New York: Wiley-Interscience, 2002.

<https://github.com/dycksont/Fatoracao-QR-e-Quadrados-Minimos>

Obrigado!